Almacenamiento: S3

Almacenamiento en la nube

El almacenamiento en la nube, por lo general, es más confiable, escalable y seguro que los sistemas de almacenamiento tradicionales en las instalaciones.

El análisis de *Big Data*, el almacenamiento de datos, el Internet de las cosas (IoT), las bases de datos y las aplicaciones de copias de seguridad y archivo dependen de algún tipo de arquitectura de almacenamiento de datos.

El almacenamiento más básico es el que incluyen las propias instancias, también conocido como el **almacén de instancias**, o almacenamiento efímero, es un almacenamiento temporal que se agrega a la instancia de EC2.

El almacén de instancias es una buena opción para el almacenamiento temporal de información que cambia con frecuencia, como *buffers*, memorias caché, datos de pruebas y demás contenido temporal que no necesita persistencia. También se puede utilizar para los datos que se replican en una flota de instancias, como un grupo de servidores web con balanceo de carga. Si las instancias se detienen, ya sea debido a un error del usuario o un problema de funcionamiento, se eliminarán los datos en el almacén de instancias.

Almacenamiento de bloque o de objeto

AWS permite almacenar los datos en bloques o como objetos. Si nos centramos en el **almacenamiento por bloques**, los datos se almacenan por trozos (bloques), de manera si se modifica una parte de los datos, solo se ha de modificar el bloque que lo contiene. El almacenamiento de bloque es el tipo de almacenamiento que ofrecen los discos SSD y HDD, donde los bloques o fragmentos suelen ser de 4096 bytes.

En cambio, si el **almacenamiento es a nivel de objeto**, una modificación implica tener que volver a actualizar el objeto entero (los objetos son inmutables). Esto provoca que el almacenamiento por bloque sea más rápido, al no tener que utilizar bloqueos o sincronizar cambios sobre un mismo archivo. En consecuencia, el almacenamiento de objetos es más sencillo y por tanto más barato.

Además, el ancho de banda de lectura puede escalar mediante peticiones en paralelo, de forma proporcional a la cantidad de recursos empleados para leer los datos (máquinas y CPUs), lo que hace que sea un almacenamiento ideal para servir contenido web que tiene un alto tráfico o emplearse por los motores de consultas distribuidos que trabajan con datos en paralelo.

AWS ofrece múltiples soluciones que vamos a revisar:

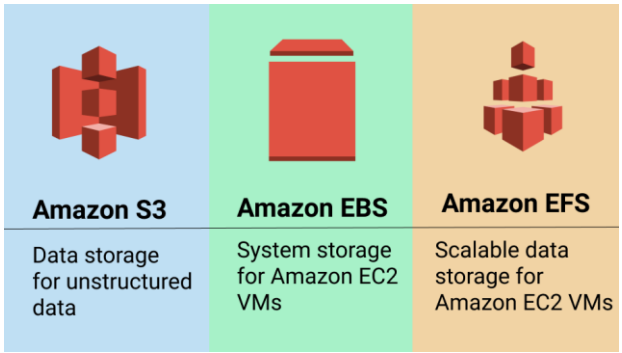

Servicios de almacenamiento de AWS

Amazon EBS

Amazon Elastic Block Store (https://aws.amazon.com/es/ebs/) ofrece volúmenes de almacenamiento a nivel de bloque de alto rendimiento para utilizarlos con instancias de Amazon EC2 para las cargas de

trabajo con un uso intensivo de transacciones y de rendimiento. Realmente, sólo emplearemos almacenamiento EBS en combinación con instancias EC2.

Los beneficios adicionales de EBS son la replicación en la misma zona de disponibilidad, el cifrado fácil y transparente, los volúmenes elásticos y las copias de seguridad mediante instantáneas.

Volúmenes

IOPS

El término IOPS, *operaciones de entrada y salida por segundo*, representa una medida de rendimiento frecuente que se utiliza para comparar dispositivos de almacenamiento.

Los volúmenes de EBS proporcionan almacenamiento externo a EC2 que persiste independientemente de la vida de la instancia. Son similares a discos virtuales en la nube. *AmazonEBS* ofrece tres tipos de volúmenes: SSD de uso general, SSD de IOPS provisionadas y magnéticos (HDD). Los tres tipos de volúmenes difieren en características de rendimiento y coste, para ofrecer diferentes posibilidades según las necesidades de las aplicaciones:

- *Unidades de estado sólido (SSD)*: optimizadas para cargas de trabajo de transacciones que implican operaciones de lectura/escritura frecuentes de pequeño tamaño de E/S. Proporciona un equilibrio entre precio y rendimiento, y es el tipo recomendado para la mayoría de las cargas de trabajo. Los tipos existentes son gp3 (1.000 MiB/s) y gp2(128-250 MiB/s) ambas con un máximo de 16.000 IOPS.
- *SSD de IOPS provisionadas*: proporciona un rendimiento elevado con cargas de trabajo críticas, baja latencia o alto rendimiento. Los tipos existentes con io2 Block Express (4.000 MiB/s con un máximo 246.000 IOPS) e io2 (1.000 MiB/s con 64.000 IOPS)
- *Unidades de disco duro (HDD)*: optimizadas para grandes cargas de trabajo de *streaming*. Los tipos existentes con st1 (*Throughput Optimized HDD*, con 500 MiB/s y 500 IOPS) y sc1 (*Cold HDD*, con 250 MiB/s y 250 IOPS).

Más información sobre los diferentes volúmenes: https://docs.aws.amazon.com/es_es/AWSEC2/latest/UserGuide/ebs-volume-types.html

Para crear o configurar un volumen, dentro de las instancias EC2, en el menú lateral podemos ver las opciones de *Elastic Block Store* y el submenú *Volúmenes*:

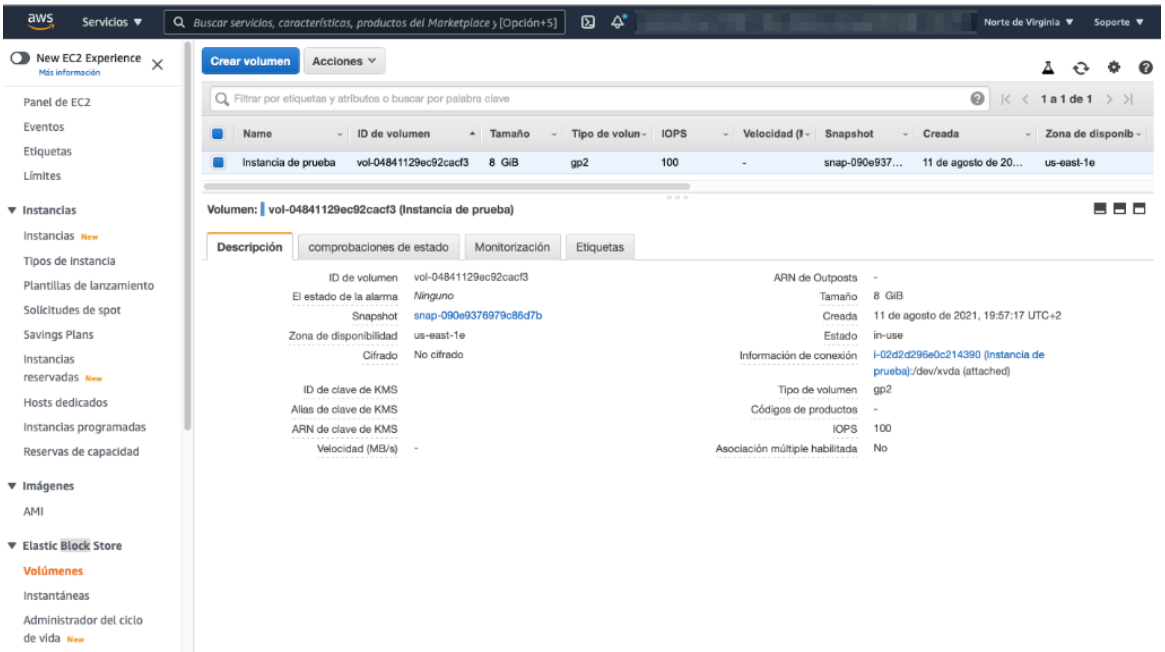

Volúmenes en EBS

Los volúmenes de Amazon EBS están asociados a la red, y su duración es independiente a la vida de una instancia EC2. Al detener la instancia EC2, el volumen EBS permanece.

Al tener un alto nivel de disponibilidad y de confianza, se pueden aprovechar como particiones de arranque de instancias de EC2 o asociarse a una instancia de EC2 en ejecución como dispositivos de bloques estándar (como un disco duro típico para ampliar la capacidad de almacenamiento).

Cuando se utilizan como particiones de arranque, las instancias de Amazon EC2 pueden detenerse y, posteriormente, reiniciarse, lo que le permite pagar solo por los recursos de almacenamiento utilizados al mismo tiempo que conserva el estado de la instancia. Los volúmenes de Amazon EBS se **replican automáticamente** en el *backend* (en una única zona de disponibilidad).

Los volúmenes de Amazon EBS ofrecen las siguientes características:

- Almacenamiento persistente: el tiempo de vida de los volúmenes es independiente de cualquier instancia de Amazon EC2.
- De uso general: son dispositivos de bloques sin formato que se pueden utilizar en cualquier sistema operativo.
- Alto rendimiento: ofrecen al menos el mismo o más rendimiento que las unidades de Amazon EC2 locales.
- Nivel de fiabilidad alto: tienen redundancia integrada dentro de una zona de disponibilidad.
- Diseñados para ofrecer resiliencia: la AFR (tasa anual de errores) de Amazon EBS oscila entre 0,1 % y 1 %.
- Tamaño variable: los tamaños de los volúmenes varían entre 1 GB y 16 TB.
- Fáciles de usar: se pueden crear, asociar, almacenar en copias de seguridad, restaurar y eliminar fácilmente.

Instantáneas

Sin embargo, para los que quieran aún más durabilidad, con *Amazon EBS* es posible crear instantáneas uniformes puntuales de los volúmenes, que luego se almacenan en *Amazon S3* y se replican automáticamente en varias zonas de disponibilidad.

Estas instantáneas se pueden utilizar como punto de partida para nuevos volúmenes de Amazon EBS (clonando o restaurando copias de seguridad) y permiten proteger la durabilidad de los datos a largo plazo. Como todo recurso S3, también se pueden compartir fácilmente con compañeros del equipo de desarrollo y otros desarrolladores de AWS.

Amazon EFS

Amazon Elastic File System (https://aws.amazon.com/es/efs/) ofrece almacenamiento para las instancias EC2 a las que pueden acceder varias máquinas virtuales de forma simultánea, de manera similar a un NAS (*Network Area Storage*). Se ha implementado como un sistema de archivos de uso compartido que utiliza el protocolo de sistemas de archivos de red (NFS), al que acceden varios miles de instancia EC2 así como servidores *on-premise* a través de una VPN o conexiones directas (*AWS Direct Connect*).

Se trata de un almacenamiento de archivos simple, escalable y elástico para utilizarlo con los servicios de AWS y los recursos disponibles en las instalaciones. Mediante una interfaz sencilla permite crear y configurar sistemas de archivos de forma rápida y simple.

EFS está diseñado para escalar a petabytes de manera dinámica bajo demanda sin interrumpir las aplicaciones, por lo que se ampliará y reducirá de forma automática a medida que agregue o elimine archivos, no necesitando asignar espacio inicial.

Las instancias se conectan a EFS desde cualquier AZ de la región. Todas las lecturas y escrituras son consistentes en todas las AZ. Por ejemplo, una lectura en una AZ garantiza que tendrá la misma información, aunque los datos se hayan escrito en otra AZ.

Respecto al coste (https://aws.amazon.com/es/efs/pricing/), dependiendo del tipo de acceso y la administración del ciclo de vida, el acceso estándar se factura desde 0,30$ Gb/mes, mientras que si el acceso es poco frecuente, baja a 0,013$ Gb/mes más 0,01$ por transferencia y Gb/mes.

Su casos de uso más comunes son para *Big Data* y análisis, flujos de trabajo de procesamiento multimedia, administración de contenido, servidores web y directorios principales.

Respecto a su acceso, de manera similar al resto de servicios de almacenamiento, es un servicio completamente administrado al que se puede acceder desde la consola, una API o la CLI de AWS.

EBS y EFS conjuntamente

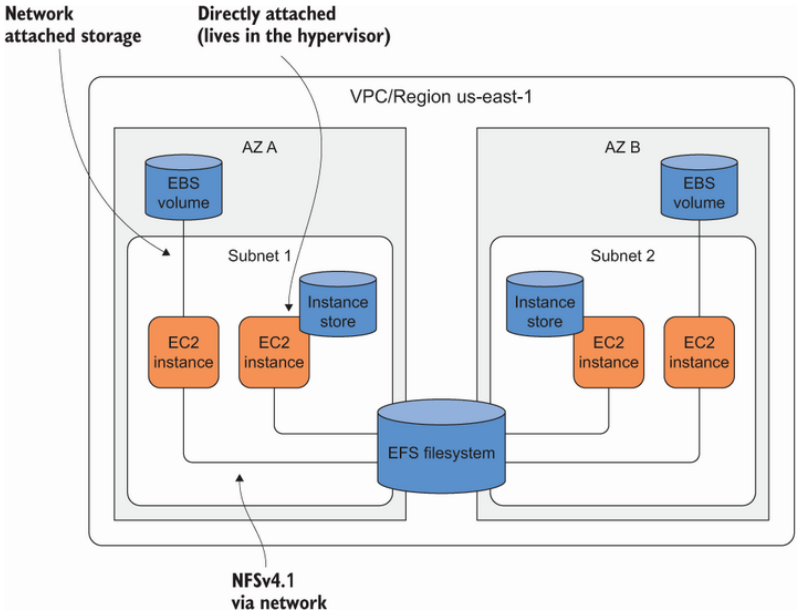

EFS compartido entre instancias

El gráfico anterior muestra cómo pueden coexistir los diferentes servicios:

- EBS es un disco virtual
- El almacenamiento de instancia es un disco local
- EFS es una carpeta compartida en red

Además, destacamos sus diferencias:

- Un volumen EBS va asociado a una única instancia EC2.
- Una unidad EFS se comparte entre varias instancias EC2, pudiendo pertenecer estas a diferentes subredes.

Amazon S3

Amazon Simple Storage Service, más conocido como *S3* (https://aws.amazon.com/es/s3/) es un servicio de almacenamiento persistente de objetos creado para almacenar y recuperar cualquier cantidad de datos desde cualquier lugar mediante una URL: sitios web y aplicaciones móviles, aplicaciones corporativas y datos de sensores o dispositivos de Internet de las cosas (IoT) y análisis de *Big Data*.

S3 es un servicio de **almacenamiento a nivel de objetos**, y tal como habíamos comentado, significa que además de que los datos contengan metadatos que ayudan a catalogar el objeto, si desea cambiar una parte de un archivo, tiene que realizar la modificación y luego volver a cargar todo el archivo modificado. Esto puede tener implicaciones de rendimiento y consistencia, que conviene tener en cuenta.

Los datos se almacenan como objetos dentro de recursos conocidos como ***buckets***. Los objetos pueden ser prácticamente cualquier archivo de datos, como imágenes, videos o registros del servidor.

Es una solución administrada de almacenamiento en la nube que se diseñó para brindar un escalado sin problemas, ofreciendo 99,99% de **disponibilidad** (4 nueves) y 99,999999999% (11 nueves) de **durabilidad**. Además de poder almacenar prácticamente todos los objetos que deseemos (capacidad de almacenamiento casi ilimitado) dentro de un *bucket* (cada objeto puede ocupar hasta un máximo de 5TB), S3 permite realizar operaciones de escritura, lectura y eliminación de los objetos almacenados en el *bucket*. ***Los nombres de los buckets son universales y deben ser únicos entre todos los nombres de buckets existentes en Amazon S3.***

De forma predeterminada, en Amazon S3 los datos se almacenan de forma redundante en varias instalaciones y en diferentes dispositivos de cada instalación.

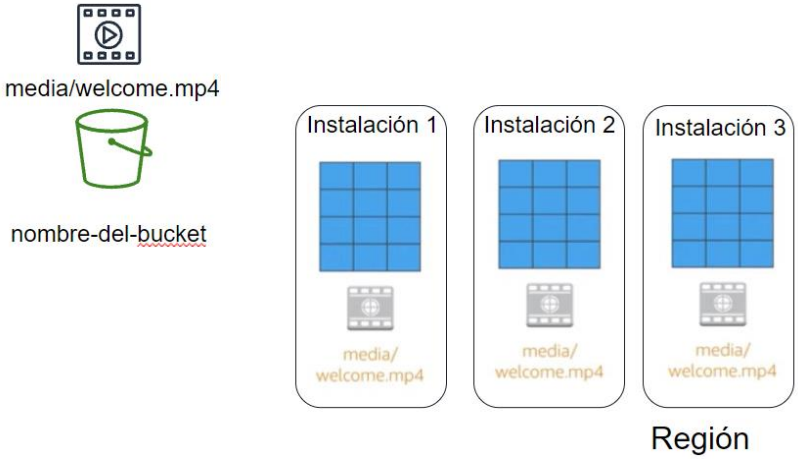

Replicación en S3

Los datos que almacenamos en *S3* no están asociados a ningún servidor en particular (aunque los *buckets* se asocien a regiones, los archivos se dice que están almacenados de forma global), con lo que no necesitamos administrar ningún tipo de servidor.

Amazon S3 contiene billones de objetos y, con regularidad, tiene picos de millones de solicitudes por segundo, por ende, es un servicio de alto rendimiento, con una latencia de primer *byte* que se mide en milisegundos para la mayoría de las clases de almacenamiento.

Elementos de un objeto

Cada objeto que almacenamos en S3 tiene:

- una clave: nombre que se le asigna al objeto y que se utiliza para recuperarlo.
- un id de versión: podemos mantener un histórico de cambios mediante el *versionado de los archivos*, de manera que cuando actualicemos un objeto, en vez de sustituirlo, se crea una nueva versión manteniendo un histórico. Más información en https://docs.aws.amazon.com/es_es/AmazonS3/latest/userguide/versioning-workflows.html
- un valor: contenido real que se almacena.
- metadatos: pares clave-valor, que podemos definir nosotros como usuarios.
- *subrecursos*: que utiliza AWS para almacenar información adicional.

Clases de almacenamiento

S3 ofrece una variedad de clases de almacenamiento (Tipos de almacenamiento en la nube | Amazon S3) a nivel de objetos que están diseñadas para diferentes casos de uso. Entre estas clases se incluyen las siguientes:

- **S3 Estándar**: diseñada para ofrecer almacenamiento de objetos de alta durabilidad, disponibilidad y rendimiento para los datos a los que se accede con frecuencia. Como ofrece baja latencia y alto nivel de rendimiento, es una opción adecuada para aplicaciones en la nube, sitios web dinámicos, distribución de contenido, aplicaciones para dispositivos móviles y videojuegos, y el análisis de *big data*.)
- **S3 Estándar - Acceso poco frecuente**: se utiliza para los datos a los que se accede con menos frecuencia, pero que requieren acceso rápido cuando es necesario. Es una opción ideal para el almacenamiento y las copias de seguridad a largo plazo, además de almacén de datos para los archivos de recuperación de desastres.
- **S3 Única zona – Acceso poco frecuente**: diseñada para guardar los datos a los que se accede con menos frecuencia, pero que requieren acceso rápido cuando es necesario, pero sin tener replicas (la clase S3 estándar replica los datos en un mínimo de tres AZ). Es una buena opción para almacenar copias de seguridad secundarias de los datos que se encuentran en las instalaciones o de los datos que se pueden volver a crear fácilmente.
- **S3 Intelligent-Tiering**: diseñada para optimizar los costes mediante la migración automática de los datos entre capas, sin que se perjudique el rendimiento ni se produzca una sobrecarga operativa. Se encarga de monitorizar los patrones de acceso de los objetos y traslada aquellos a los que no se ha accedido durante 30 días consecutivos a la capa de acceso poco frecuente. Si se accede a un objeto en la capa de acceso poco frecuente, este se traslada automáticamente a la capa de acceso frecuente. Funciona bien con datos de larga duración con patrones de acceso desconocidos o impredecibles.
- **S3 Glacier** (https://aws.amazon.com/es/s3/glacier/): es una clase de almacenamiento seguro, duradero y de bajo coste para archivar datos a largo plazo. Para que los costes se mantengan bajos, *S3 Glacier* proporciona tres opciones de recuperación (recuperación acelerada, estándar y masiva), que van desde unos pocos minutos a unas horas. Podemos cargar objetos directamente en *S3 Glacier* o utilizar políticas de ciclo de vida para transferir datos entre cualquiera de las clases de almacenamiento de S3 para datos activos y *S3 Glacier*.

  Política de ciclo de vida

  Una **política de ciclo de vida** define qué va a pasar con los datos partiendo de su almacenamiento masivo en S3 estándar, pasando a uso poco frecuente y seguidamente a Glacier y finalmente para su eliminación, en base a plazos o métricas y reduciendo costes de forma automática.

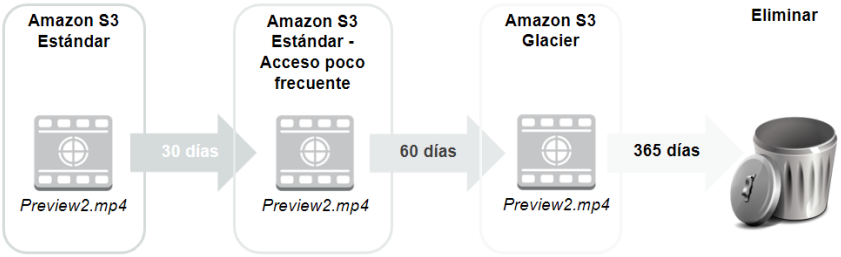

Política de ciclo de vida

  Para ello, se puede monitorizar un *bucket* completo, un prefijo o una etiqueta de objeto, de manera que podamos evaluar los patrones de acceso y ajustar la política de ciclo de vida.

- **S3 Glacier Deep Archive**: es la clase de almacenamiento de menor coste en S3. Admite la retención a largo plazo y la preservación digital de datos a los que es posible que se acceda solo una o dos veces por año. Diseñado inicialmente los a sectores con niveles de regulación muy estrictos, como los servicios financieros, la sanidad y los sectores públicos, los cuales

retienen conjuntos de datos durante un periodo de 7 a 10 años o más para cumplir los requisitos de conformidad normativa. También se puede utilizar para casos de uso de copias de seguridad y de recuperación de desastres. Todos los objetos almacenados en *S3 Glacier Deep Archive* se replican y almacenan en al menos tres zonas de disponibilidad geográficamente dispersas, y se pueden restaurar en 12 horas.

Buckets

Amazon S3 almacena los datos en *buckets*, los cuales son los bloques básicos donde se estructura la información, actuando como contenedores lógicos de objetos. Los *buckets* son esencialmente el prefijo de un conjunto de archivos y, como tales, deben tener un nombre único en todo Amazon S3 a nivel mundial.

Podemos controlar el acceso a cada *bucket* mediante mecanismos de control de acceso (*ACL*) que pueden aplicarse tanto a objetos individuales como a los *buckets*, es decir, quién puede crear, eliminar y enumerar objetos en el *bucket*. También podemos obtener registros de acceso al *bucket* y a sus objetos, además de elegir la región geográfica donde *Amazon S3* almacenará el *bucket* y su contenido. Para cargar los datos (como fotos, vídeos o documentos), primero hemos de crear un *bucket* en una región de AWS y, a continuación, cargar casi cualquier cantidad de objetos en el *bucket* (los objetos pueden ocupar hasta 5TB).

Creando un *bucket*

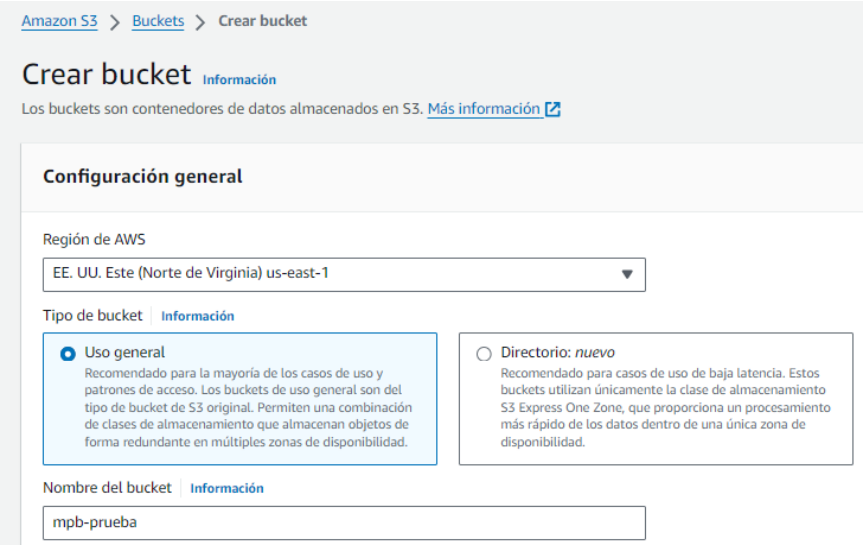

Creamos el bucket

Cuando creamos un *bucket* en S3, este se asocia a una región de AWS específica. Cuando almacenamos datos en el *bucket*, estos se almacenan de forma redundante en varias instalaciones de AWS dentro de la región seleccionada. *S3* está diseñado para almacenar los datos de forma duradera, incluso en el caso de producirse una pérdida de datos simultánea en dos instalaciones de AWS.

Por ejemplo, vamos a crear un *bucket* dentro de la región *us-east-1* (recuerda que el nombre debe ser único y en minúsculas, así como evitar las tildes, ñ, etc..).

Para ello, podemos hacerlo mediante la consola gráfica, tal como se ve en el gráfico, o haciendo uso de AWS CLI.

Cargando datos

Para almacenar un objeto en *S3*, debemos cargarlo en un *bucket*.

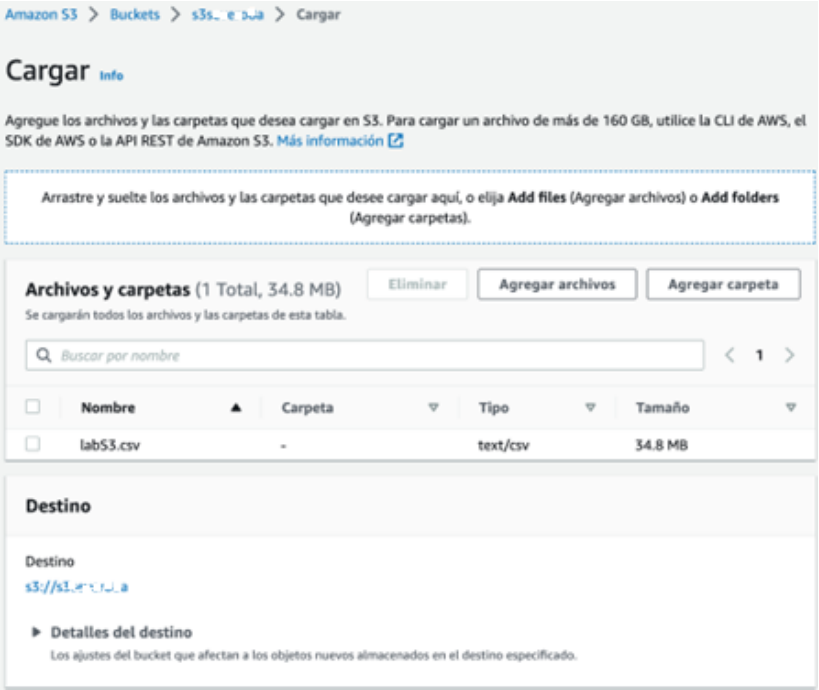

Cargando el bucket

Para cargar un archivo, una vez elegido el *bucket* sobre el que queremos cargar, simplemente arrastrando el fichero, éste se subirá a *S3* (también podemos establecer permisos sobre los datos y cualquier metadato).

Casos de uso

Ya hemos visto que *S3* administra automáticamente el almacenamiento detrás de cada *bucket* a medida que aumenta la cantidad de datos. *S3* también es escalable, lo que permite gestionar un volumen elevado de solicitudes. No es necesario aprovisionar el almacenamiento ni el rendimiento, y solo se facturará por lo que utilicemos.

Esta flexibilidad para almacenar una cantidad prácticamente ilimitada de datos y para acceder a ellos desde cualquier lugar convierte a *S3* en un servicio adecuado para distintos casos:

- Como ubicación para cualquier dato de aplicación, ya sea nuestra propia aplicación hospedada *on-premise*, como las aplicaciones de EC2 o mediante servidores en otros *hostings*. Esta característica puede resultar útil para los archivos multimedia generados por el usuario, los registros del servidor u otros archivos que su aplicación deba almacenar en una ubicación común. Además, como el contenido se puede obtener de manera directa a través de Internet, podemos delegar la entrega de contenido de nuestra aplicación y permitir que los clientes la consigan ellos mismos.
- Para el alojamiento web estático. *S3* puede entregar el contenido estático de un sitio web, que incluye *HTML*, *CSS*, *JavaScript* y otros archivos.
- Para almacenar copias de seguridad de sus datos. Para una disponibilidad y capacidad de recuperación de desastres incluso mejores, *S3* puede hasta configurarse para admitir la replicación entre regiones, de modo que los datos ubicados en un *bucket* de *S3* en una región puedan replicarse de forma automática en otra región de *S3*.

Diferencias entre EBS y S3

- *EBS* solo se puede utilizar cuando se conecta a una instancia *EC2* y se puede acceder a Amazon *S3* por sí solo.
- *EBS* no puede contener tantos datos como *S3*.

- *EBS* solo se puede adjuntar a una instancia *EC2*, mientras que varias instancias *EC2* pueden acceder a los datos de un *bucket* de *S3*.
- *S3* experimenta más retrasos que Amazon EBS al escribir datos.

Así pues, es el usuario o el diseñador de la aplicación quien debe decidir si el almacenamiento de Amazon S3 o de Amazon EBS es el más apropiado para una aplicación determinada.

Para facilitar la integración de S3 con otros servicios, S3 ofrece **notificaciones de eventos** que permiten configurar notificaciones automáticas cuando se producen determinados eventos, como la carga o la eliminación de un objeto en un *bucket* específico. Estas notificaciones se pueden enviar o utilizarse para desencadenar otros procesos, como funciones de AWS Lambda.

Costes

Con *S3*, los costes específicos varían en función de la región y de las solicitudes específicas que se realizan. Solo se paga por lo que se utiliza, lo que incluye gigabytes por mes; transferencias desde otras regiones; y solicitudes PUT, COPY, POST, LIST y GET. Como regla general, solo se paga por las transferencias que cruzan el límite de su región, lo que significa que no paga por las transferencias entrantes a *S3* ni por las transferencias salientes desde *S3* a las ubicaciones de borde de Amazon CloudFront dentro de esa misma región.

Para calcular los costes de *S3* hay que tener en cuenta:

1. Clase de almacenamiento y cantidad almacenada:
    - El almacenamiento estándar está diseñado para proporcionar 99,999.999.999% (11 nueves) de durabilidad y 99,99% (4 nueves) de disponibilidad. Por ejemplo, los primeros 50 TB/mes cuestan 0,023$ por GB.
    - El almacenamiento Estándar - Acceso poco frecuente ofrece la misma durabilidad de 99,999.999.999% (11 nueves) de *S3*, pero con 99,9% (3 nueves) de disponibilidad en un año concreto. Su precio parte desde los 0,0125$ por GB.
    - Y si elegimos el almacenamiento poco frecuente, pero en una única zona, el precio pasa a ser de 0,01$ por GB.
    - Si fuese a la capa *Glacier*, con una opción de recuperación de 1 minutos a 12 horas el precio baja a 0,004$ por GB.
    - Finalmente, con *Glacier Deep Archive* (archivos que se recuperan 1 o 2 veces al año con plazos de recuperación de 12 horas) baja hasta 0,00099$ por GB
2. Solicitudes: se consideran la cantidad y el tipo de las solicitudes. Las solicitudes GET generan cargos (0,0004$ por cada 1.000 solicitudes) a tasas diferentes de las de otras solicitudes, como PUT y COPY (0,005$ cada 1.000 solicitudes).
3. Transferencia de datos: se considera la cantidad de datos transferidos fuera de la región de *S3*, los datos salientes, siendo los primeros 100 GB gratuito y luego comienza a facturar a 0,09$ por GB. La transferencia entrante de datos es gratuita.

La información actualizada y detallada se encuentra disponible en https://aws.amazon.com/es/s3/pricing/.

Versionado de objetos

Versionado en S3

Cuando hemos visto los metadatos de un objeto, hemos podido observar que cada objeto contiene un atributo versión. El servicio S3 permite almacenar un histórico con todas las versiones de un objeto, y poder conservar, recuperar y restaurar todas las versiones de los objetos almacenados en un *bucket*.

Para ello, el primer paso es habilitar el control del versiones para el bucket. Para ello, bien mediante la consola, en las propiedades del *bucket* habilitamos el *Control de versiones*:

Habilitando el control de versiones

Ahora, al recuperar un objeto, siempre recuperará la última versión. Pero ¿y si queremos una versión diferente?

Desde la consola, al seleccionar un archivo, en la pestaña *Versiones*, podemos hacer clic en la versión deseada y descargarla:

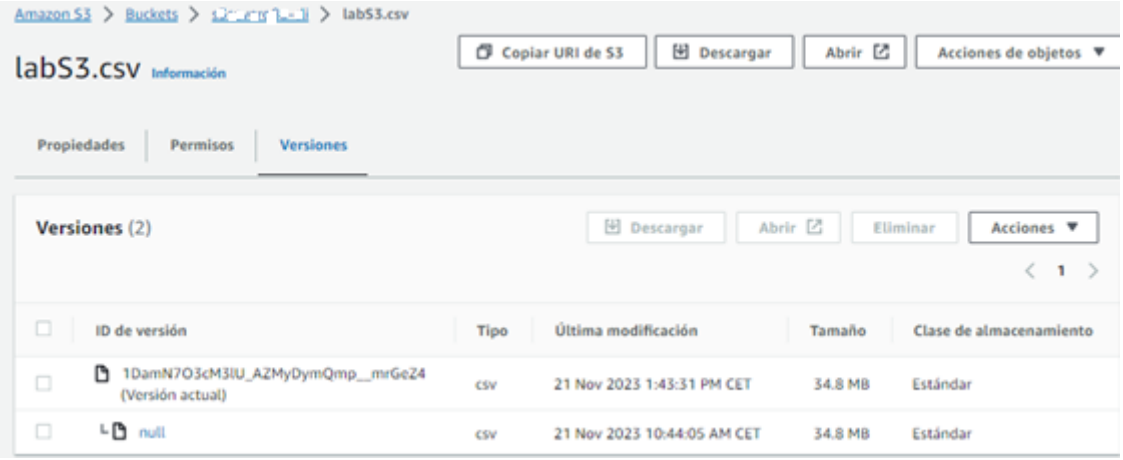

Visualizando las versiones

Coste del versionado

AWS no cobra ningún extra por habilitar el versionado, sólo que al añadir un nuevo archivo, se creará una nueva versión y por tanto, un nuevo objeto. Así pues, si tenemos 4 versiones de un objeto, pagaremos por los cuatro objetos.

S3 Select

Amazon S3 Select permite utilizar instrucciones SQL sencillas para filtrar el contenido de los objetos de Amazon S3 y recuperar exactamente el subconjunto de datos que necesitemos. Si utilizamos *S3 Select* para filtrar los datos, podemos reducir la cantidad de datos que Amazon transfiere, lo que reduce también los costes y la latencia para recuperarlos.

Admite los formatos *CSV*, *JSON* o *Apache Parquet*, ya sea en crudo o comprimidos con *GZIP* o *BZIP2* (solo para objetos *CSV* y *JSON*), así como objetos cifrados del lado del servidor.

Las expresiones SQL se pasan a Amazon S3 en la solicitud, siendo Amazon S3 Select compatible con un subconjunto de SQL. Para obtener más información sobre los elementos SQL compatibles es recomendable consultar la referencia SQL de S3.

Respecto a los costes, el uso de *S3Select* tiene un coste de 0,002$ por cada GB escaneado, y 0,0007$ por cada GB devuelto tras ejecutar la consulta.

Consulta SQL

Por ejemplo, si trabajamos sobre el *bucket* que habíamos creado, tras seleccionarlo, en las *Acciones de objeto*, elegiremos la opción de *Consultar con S3 Select* , y si no queremos configurar nada, podemos ejecutar una consulta de tipo *select* desde la propia ventana mediante el botón *Ejecutar consulta SQL*.

```
SELECT * FROM s3object s LIMIT 5
```

Si nos fijamos en la imagen, se crea una tabla ficticia denominada `s3object` que referencia al documento cargado. Si queremos hacer referencia a columna, podemos hacerlo por su posición (por ejemplo s._1 referencia a la primera columna) o por el nombre de la columna (en nuestro caso, `s.VendorID`).

```
SELECT * FROM s3object s WHERE s.VendorID='1' LIMIT 5
```

Es importante marcar la casilla *Excluir la primera línea de CSV datos* si la primera fila de nuestro CSV contiene etiquetas a modo de encabezado.

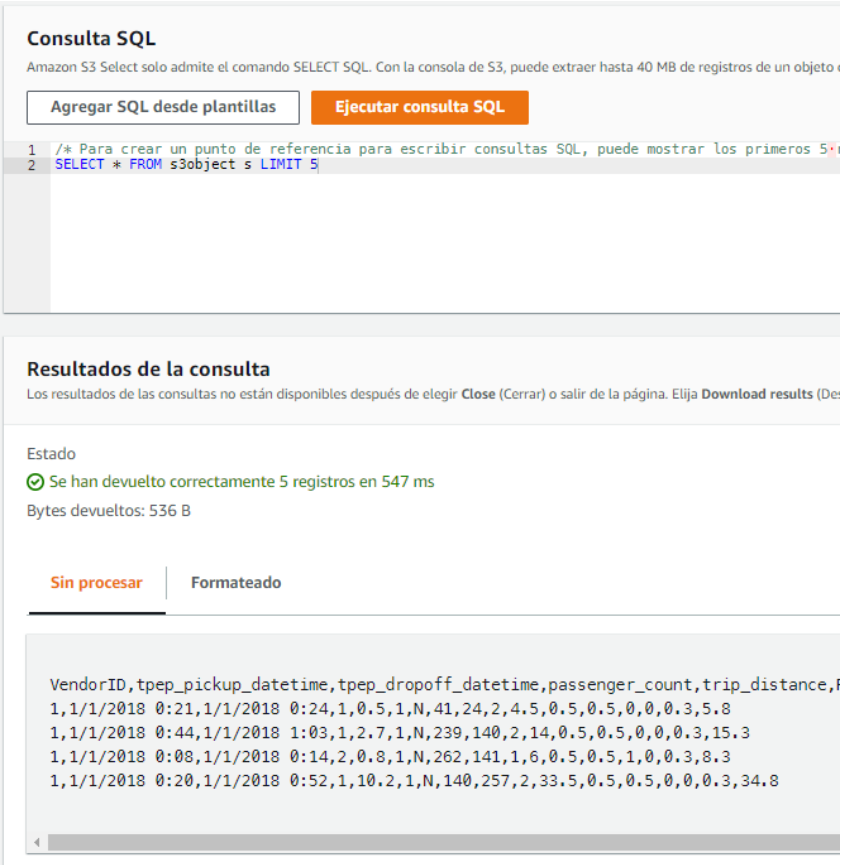

Consulta sobre S3Select

Si pulsamos sobre el botón de *Agregar SQL desde plantillas*, podremos seleccionar entre algunas consultas predefinidas (contar, elegir columnas, filtrar los datos, etc..).

La consola de Amazon S3 limita la cantidad de datos devueltos a 40 MB. Para recuperar más datos, deberemos utilizar la AWS CLI o la API REST.

Más información en https://docs.aws.amazon.com/es_es/AmazonS3/latest/userguide/selecting-content-from-objects.html.

Seguridad

Por defecto, todos los *buckets* de S3 son privados y solo pueden acceder los usuarios a los que se les concede acceso explícitamente. Normalmente utilizaremos S3 para almacenar datos que utiliza una

aplicación que se ejecuta fuera de S3 o para hacer copias de seguridad de información confidencial. Para estos casos de uso comunes, el acceso público a los *buckets* que contienen datos nunca debe ser otorgado.

Disponemos de varias herramientas y posibilidades para controlar el acceso a los *buckets* u objetos de S3:

- Uso del bloqueo de acceso público, la cual anula de manera sencilla cualquier otra política o permisos de objetos.
- La escritura de políticas IAM que indiquen los usuarios o roles que pueden acceder a *buckets* y objetos específicos.
- La escritura de políticas de *bucket* que definan el acceso a *buckets* u objetos específicos, ya sea para conceder acceso entre cuentas de AWS o para conceder acceso público o anónimo a los datos de Amazon S3. Se utiliza cuando el usuario o el sistema no pueden autenticarse mediante IAM.
- Creación de puntos de acceso de S3, los cuales son nombres de alojamiento únicos que aplican permisos y controles de red definidos para las solicitudes que se realizan a través de él. Podemos crear puntos de acceso individualizados con nombres y permisos personalizados para cada aplicación que accede a los datos.
- Configuración de listas de control de acceso (ACL). Se utilizan con menos frecuencia (las ACL preceden a la IAM). Si utilizamos ACL, se recomienda no establecer un acceso muy permisivo.

La seguridad es crítica

Recuerda que hay que controlar el acceso a los recursos, y en especial a S3. Si lo dejamos abierto, cualquier podrá introducir datos con el consiguiente incremento en el coste. También podemos cifrar los datos en tránsito y habilitar el cifrado del lado del servidor en nuestros objetos.