AWS Glue II

AWS Glue es la herramienta ETL *serverless* completamente administrada que ofrece Amazon Web Services, con la cual podemos crear soluciones basadas en código tanto para la ingesta como para la transformación de los datos.

AWS Glue incluye un amplio conjunto de conectores tanto para los servicios AWS (RDS, S3, Redshift, etc.) como para servicios de terceros (MongoDB, MongoDB Atlas, conectores JDBC, etc.)

Como vimos en el tema anterior, cuando el esquema de los datos es desconocido, AWS Glue permite inferirlo. Para ello, hemos de construir un rastreador (*crawler*) para descubrir su estructura.

Con esa información, Glue crea un catálogo que contiene metadatos sobre las diferentes fuentes de datos (compatible con el Hive Catalog).

Además de los rastreadore Glue incorpora otra serie de componentes que nos permiten la automatización de las tareas de ETL.

Finalmente, Glue simplifica la orquestación de las ETL, permitiendo ejecutar miles de *jobs* en *workflows* y desarrollar e incluso poder administrarlos de forma visual.

Componentes

AWS Glue tiene varios componentes que podrían haberse dividido en varios servicios independientes, pero suelen trabajar todos juntos, por lo que AWS los ha agrupado en la familia AWS Glue.

A continuación, vamos a examinar los componentes principales de Glue relacionados con el procesamiento de datos.

Glue ETL jobs

Glue permite trabajar con diferentes motores de integración mediante Python, Spark y Ray para el procesamiento de datos almacenados en diferentes fuentes como S3 o RDS y registrados en el AWS Glue Data Catalog.

Las diferentes tareas ETL se facturan por DPUs (Data Processing Units) utilizadas y la cantidad de tiempo empleado en la ejecución (de forma similar a AWS Lambda). Aproximadamente, y dependiendo de la tecnología, cada DPU cuesta 0,44$ por hora. Más información en la página oficial de precios de AWS Glue.

La siguiente imagen muestra una posible configuración de DPUs, con dos de los motores Glue (un único nodo Python mediante *shell* a la izquierda, y un clúster de nodos Spark a la derecha):

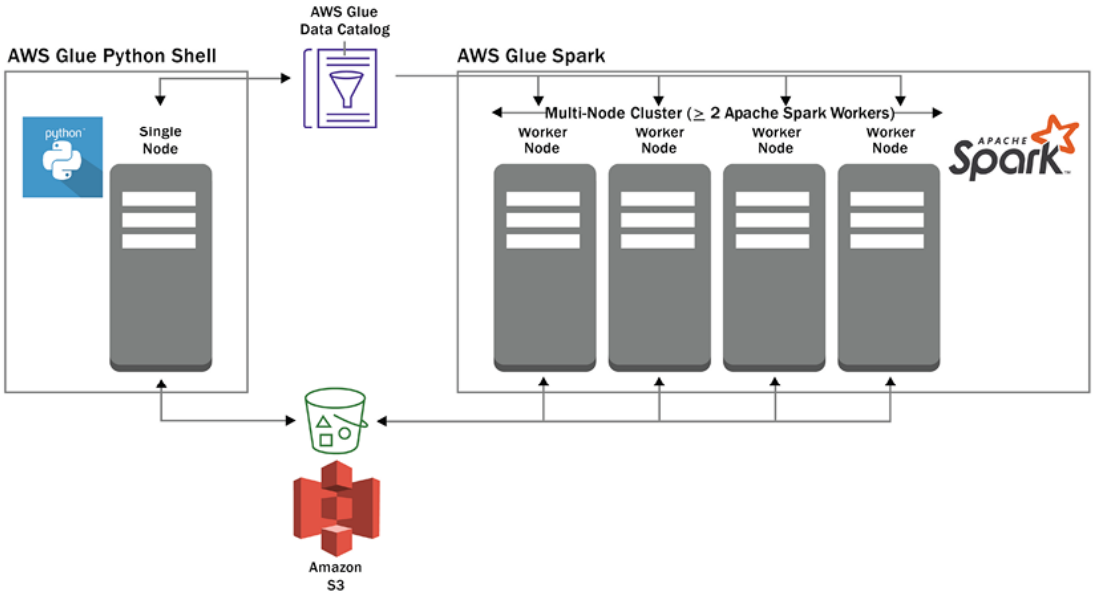

Un shell de Python en Glue Python y un clúster de Spark

Glue Studio

Por ejemplo, mediante Glue Studio vamos a crear una ETL utilizando herramientas visuales preprogamadas o programas en Python o Spark para realizar distintas operaciones de Extracción, Transformación y Carga de Datos.

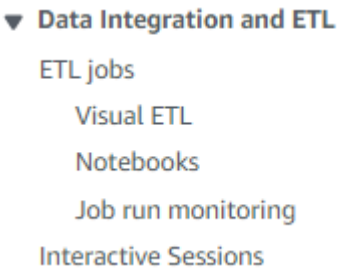

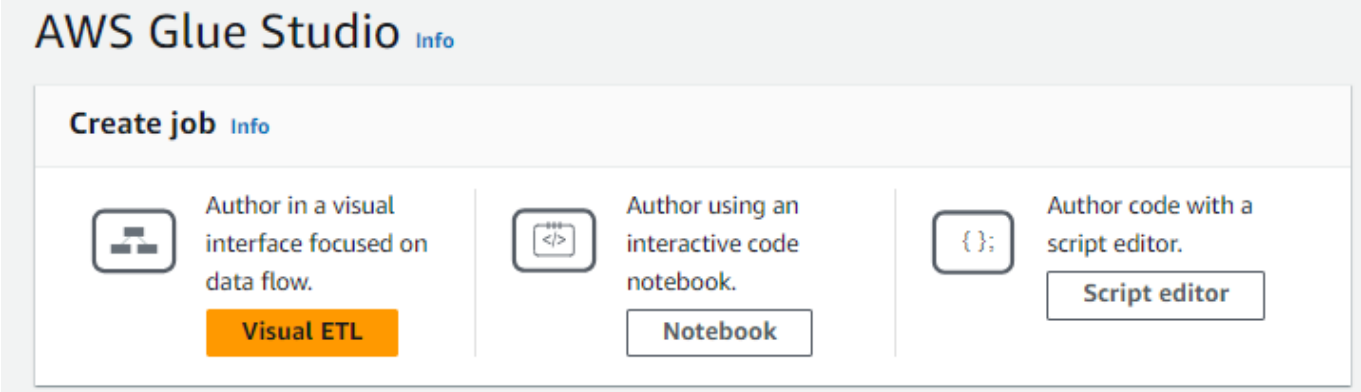

Realizando la extracción

Veremos un ejemplo en Glue Studio desde el interfaz de Visual ETL. En él realizaremos una operación JOIN entre dos tablas (ventas y productos) previamente cargadas con un *crawler* en el Data Catalog y crear nuestra ETL arrastrando como fuente una tabla del catálogo (como se ve en la imagen hay otras fuentes de datos disponibles):

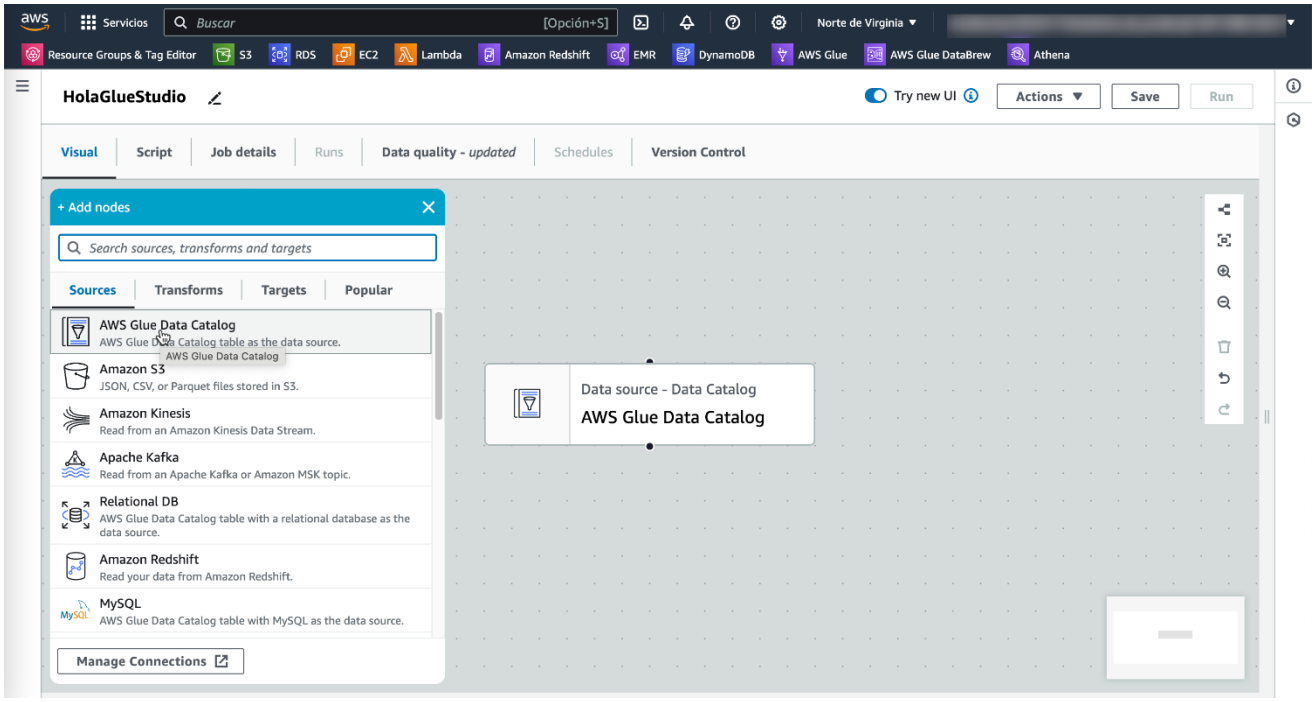

Hola Glue Studio - Tabla del catálogo como fuente

Una vez seleccionado el elemento, seleccionamos la base de datos, en el ejemplo ***iabd***, la tabla ***ventas*** y utilizamos el LabRole que nos ofrece AWS Academy.

Tras seleccionarlo, Glue Studio nos mostrará una previsualización de los datos:

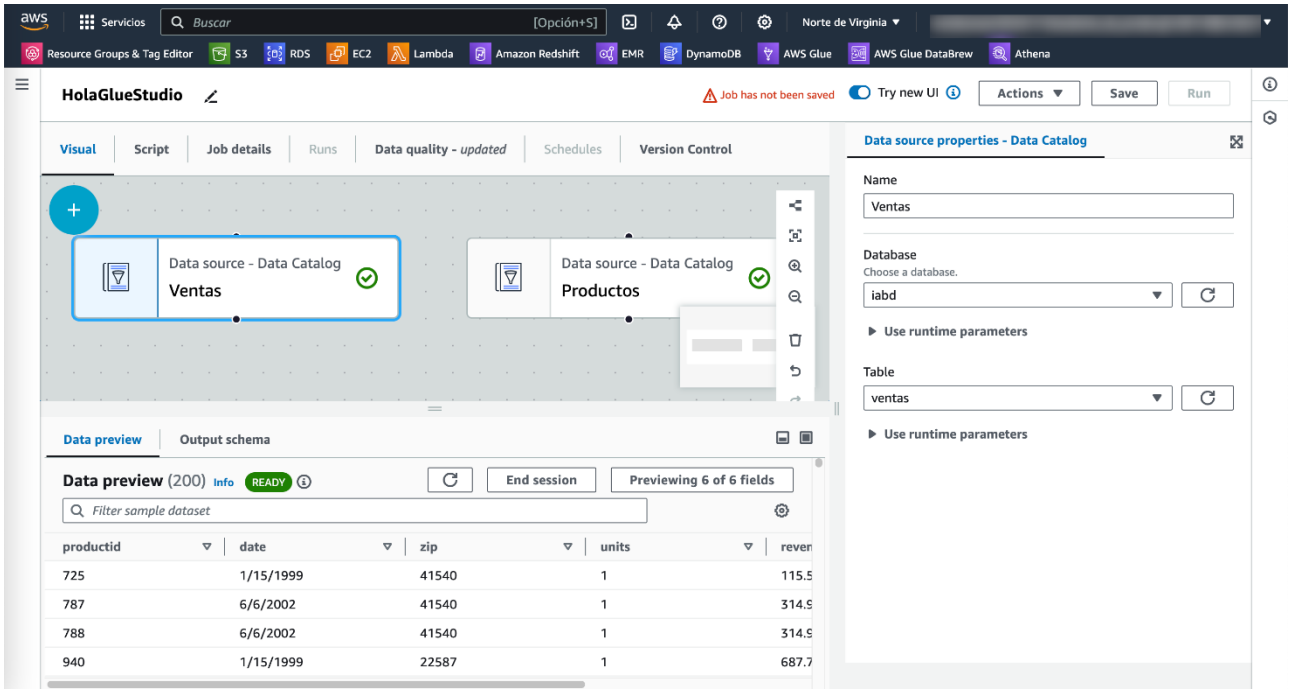

Glue Studio - Tabla de ventas

A continuación, repetimos el proceso, pero ahora con la tabla ***productos***.

Transformando los datos

Una vez cargados los datos, desde la pestaña de Transformaciones, seleccionamos el componente de ***Join***:

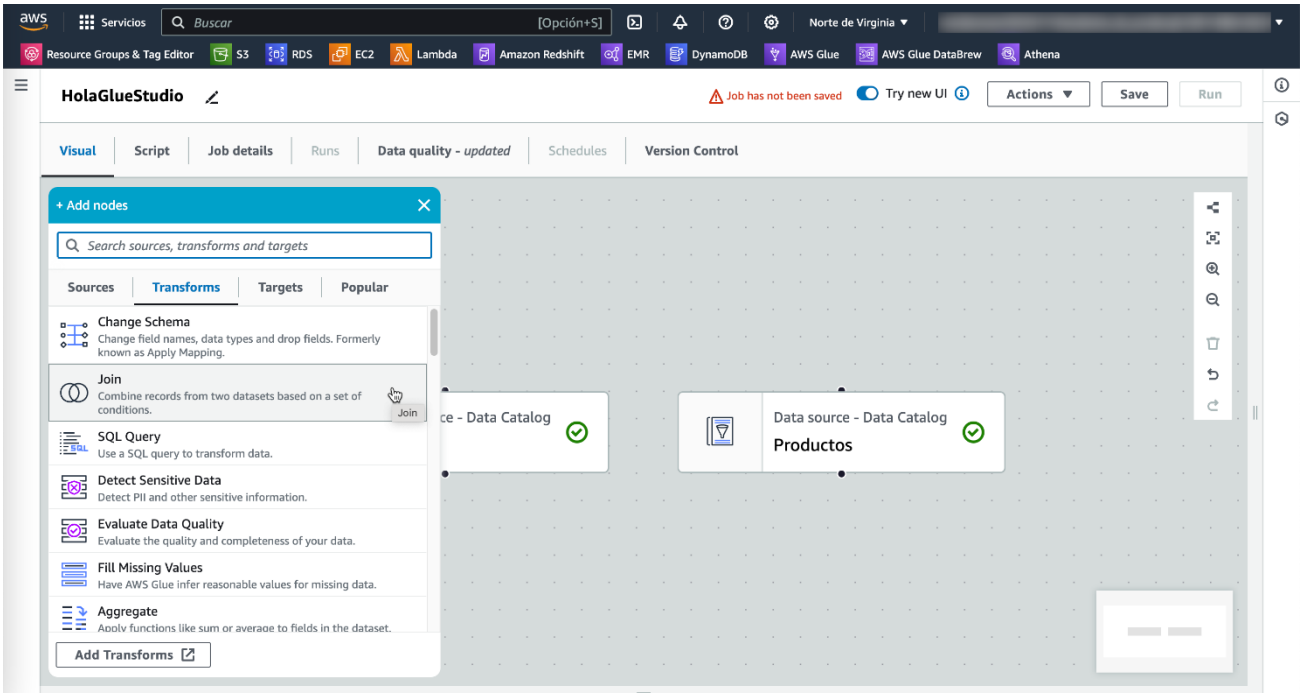

Glue Studio - Componente Join

Y configuramos el ***Join*** seleccionando ambas tablas e indicando la condición de clave ajena con clave primaria:

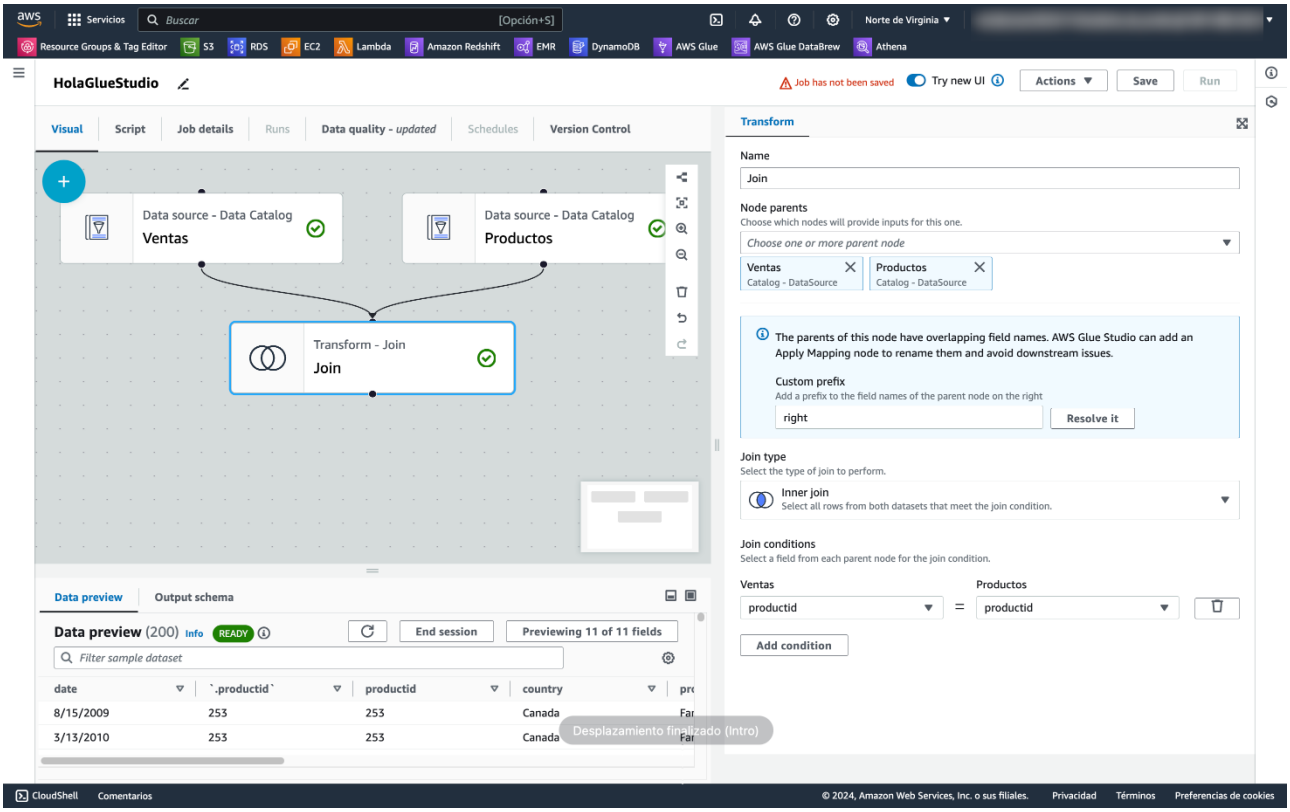

Glue Studio - Componente Join

Como ahora tenemos dos campos *productid*, añadimos otra transformación de **Drop Field**s para eliminar la columna duplicada:

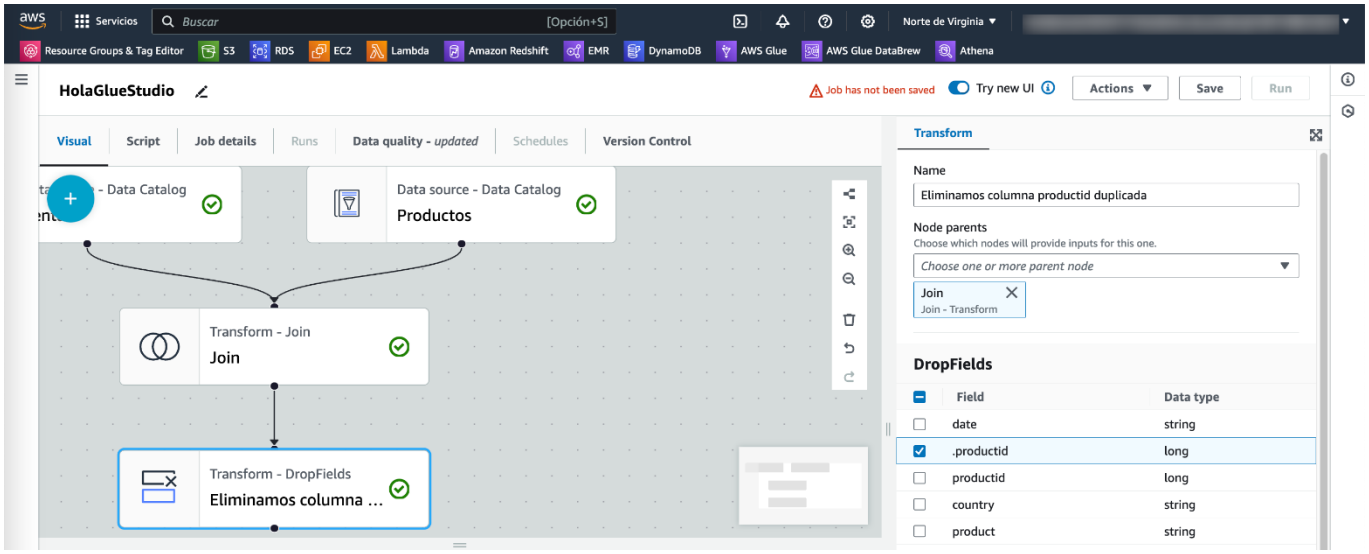

Eliminando columna duplicada

Seleccionamos la carga

Y, para terminar, vamos a almacenar el resultado en S3 en formato Parquet particionando los datos por país (country) y crear una tabla en el catálogo que apunte a dichos datos.

Para ello, primero elegimos para el destino el servicio S3 y configuramos el nodo padre, el formato Parquet y la ruta de destino (en nuestro caso, le ponemos una nueva carpeta ventas-productos):

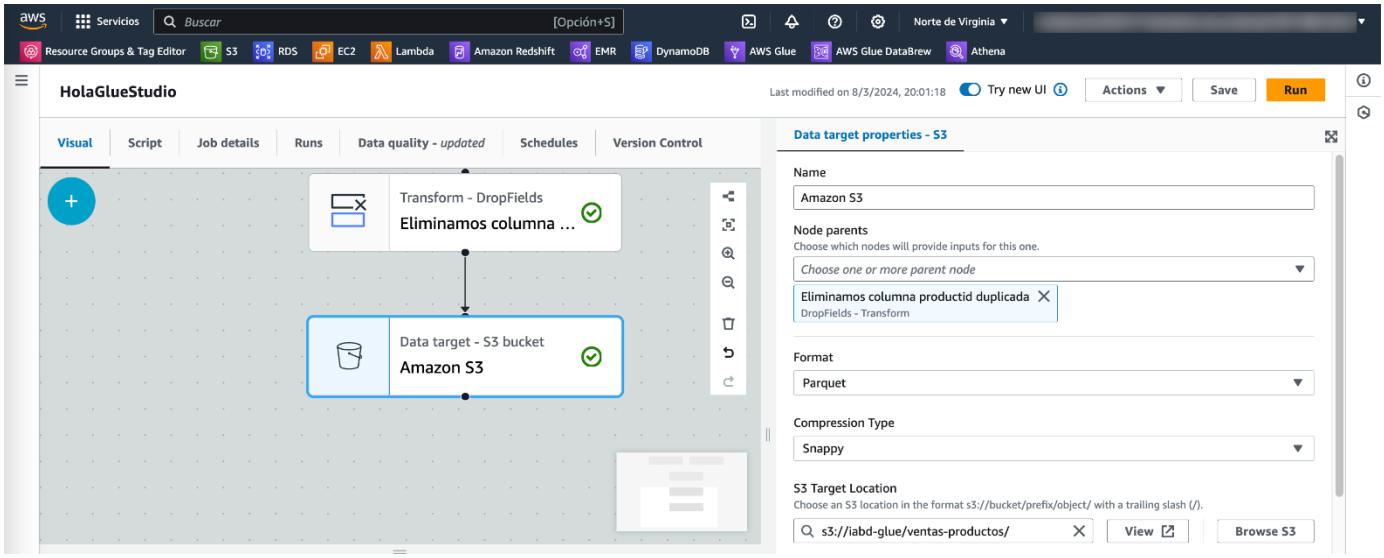

Hola Glue Studio - Eliminando columna duplicada

Y a continuación le pedimos que guarde una tabla en el catálogo en la base de datos ***iabd*** en una nueva tabla que llamamos ***ventas_productos***:

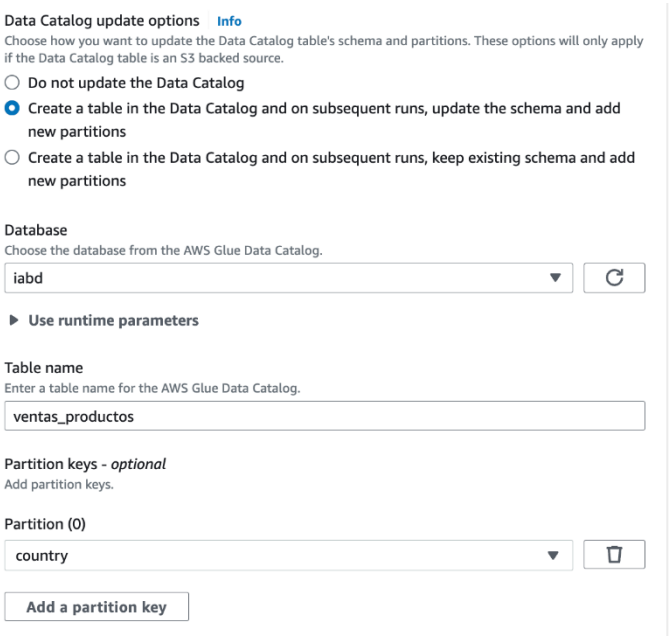

Glue Studio – Actualizando el catálogo de datos con la nueva tabla

Probamos la ETL

Tras grabar, ya tenemos lista nuestra ETL y la ejecutamos mediante el botón *Run* naranja situado en la esquina superior derecha.

Si vamos a la pestaña *Runs* de nuestra ETL, podremos ver el estado y tiempo de ejecución (2m50s lo cual es mucho tiempo para tan poca cantidad de datos, pero el procesamiento distribuido tiene una sobrecarga que, en volúmenes pequeños de datos, penaliza).

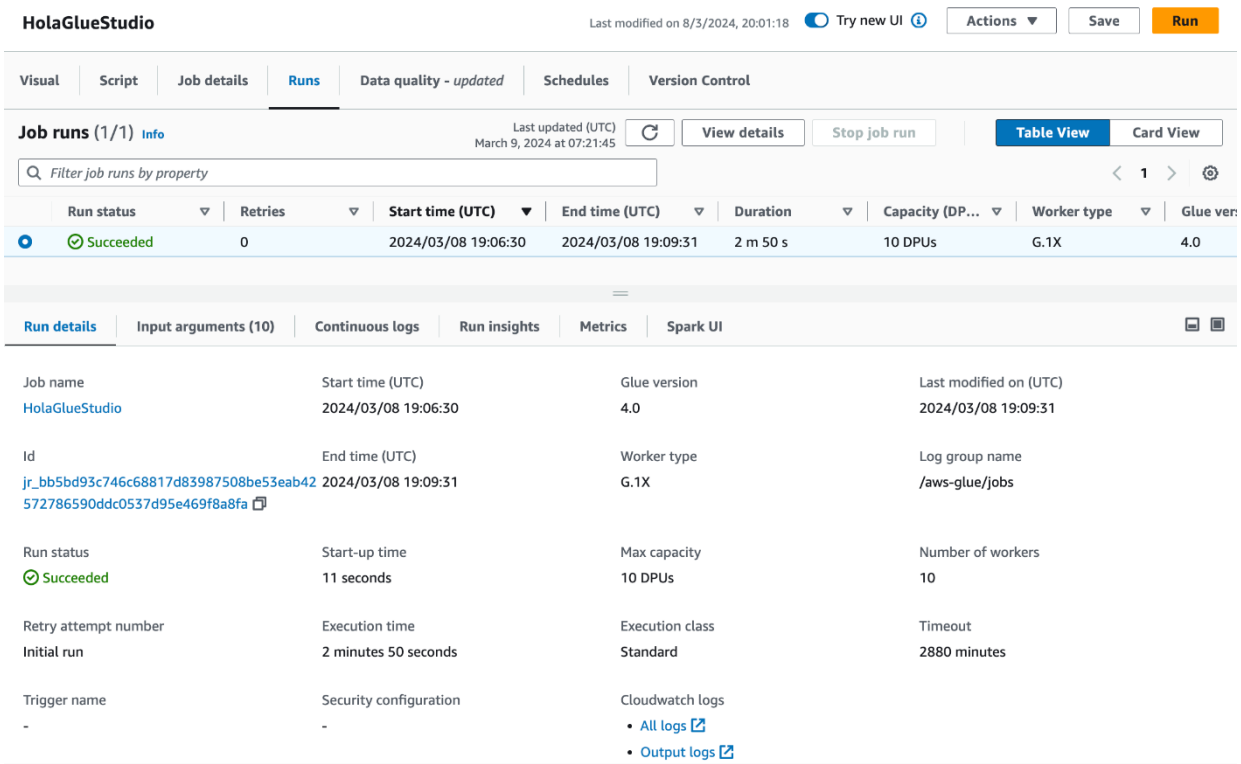

Glue Studio - Estadísticas de la ejecución

Y el último paso es comprobar cómo en S3 se han creado los datos particionados por país:

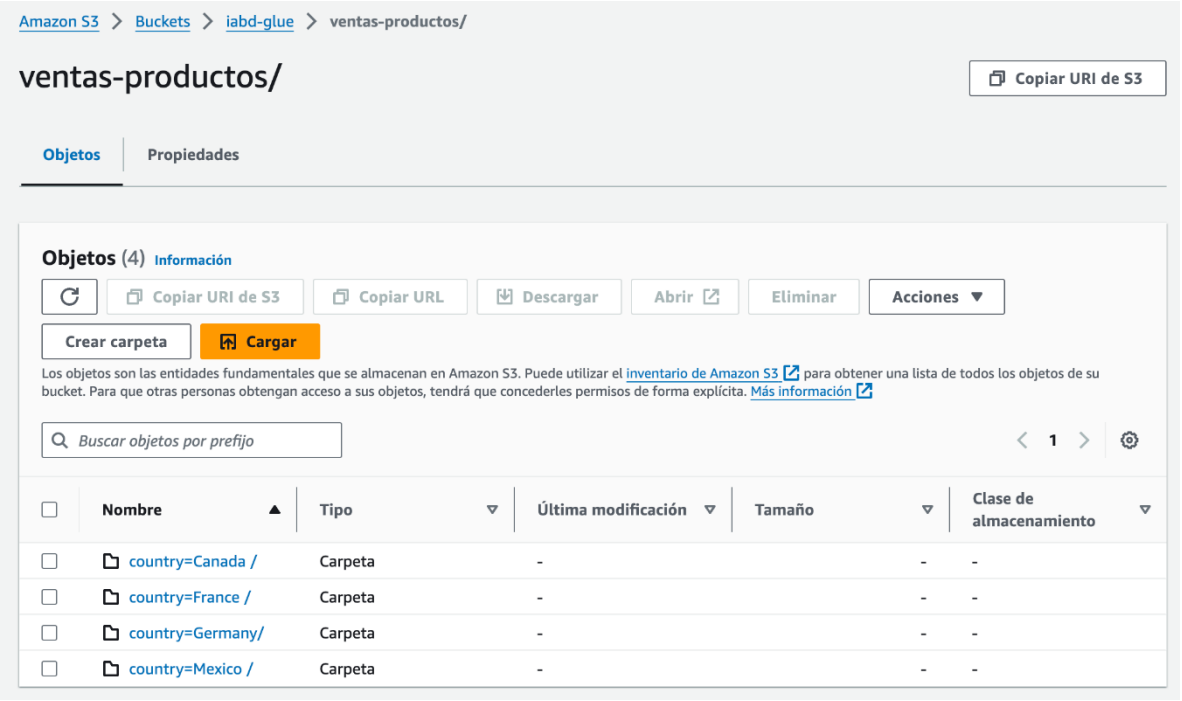

Glue Studio - Datos particionados por país

Glue Triggers (Disparadores)

[AWS Glue triggers - AWS Glue (amazon.com)]

Los disparadores nos permiten concatenar trabajos y rastreadores en función de determinados eventos.

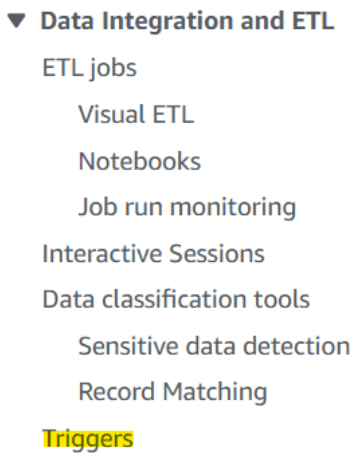

Pueden ser de tres tipos:

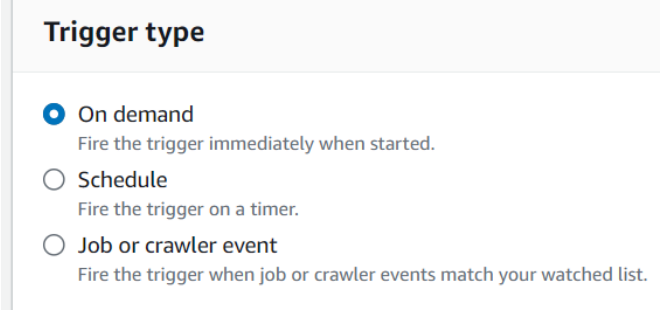

Lanzados manualmente, programados por fechas o que se lancen en función de un determinado evento procedente del resultado de la ejecución de un trabajo o disparador. En este último caso debemos seleccionar el trabajo o rastreador previamente programado y el evento al que ha de responder:

Por ejemplo, seleccionamos un trabajo que carga los datos de las estaciones meteorológicas de España a partir de los datos mundiales que tenemos en un *bucket:*

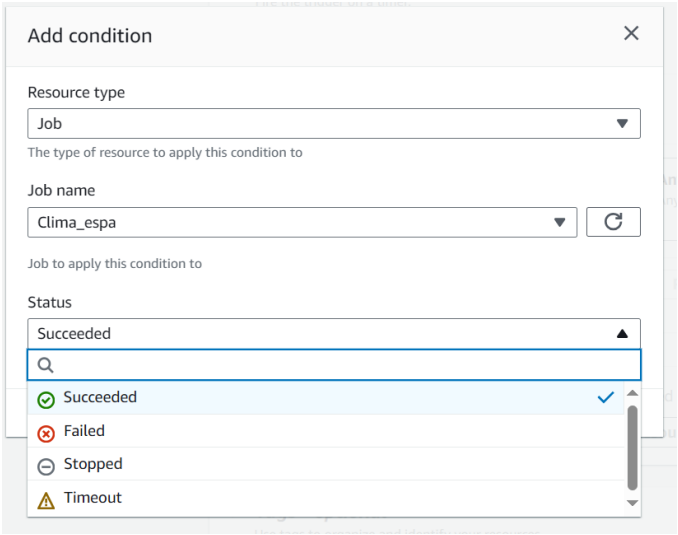

Si añadimos más de un trabajo o rastreador habría que configurar si queremos que se lance el trabajo posterior una vez finalizadas todas las tareas previas o solamente alguna de ellas:

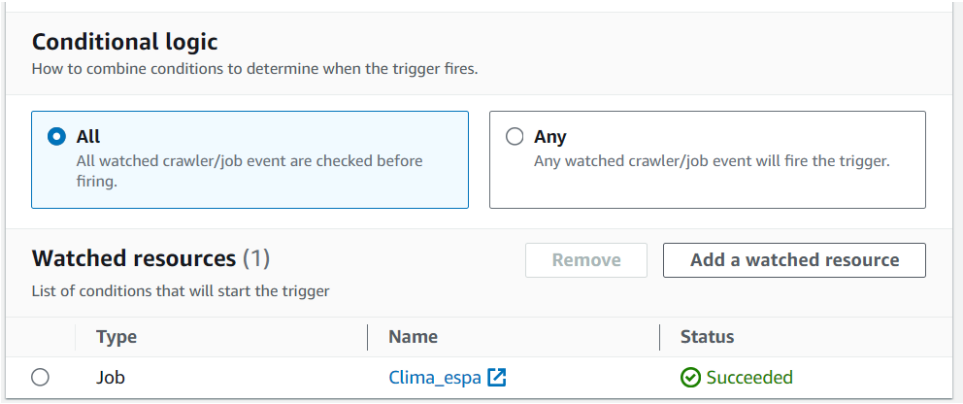

En el siguiente paso seleccionaremos el trabajo o rastreador que queremos que se active después de finalizado el trabajo con éxito (en el ejemplo podría ser un rastreador que nos crea el catálogo de datos para una nueva tabla con solo las estaciones meteorológicas españolas que ya están en nuestro *bucket* como resultado del trabajo anterior):

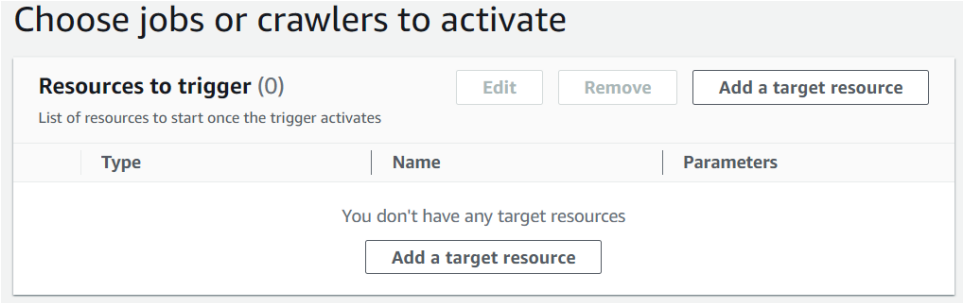

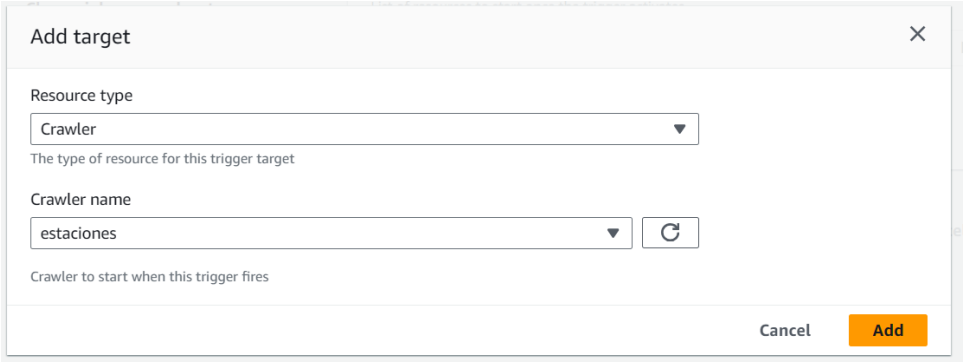

Como resultado de todo ello, después de lanzado nuestro trabajo que copia los ficheros de las estaciones meteorológicas españolas a nuestro S3 debería lanzarse automáticamente el rastreador que lo añade al catálogo de datos. Es decir, deberíamos tener los ficheros de las estaciones en nuestro *bucket* y la tabla con sus campos añadida al *Data Catalog* disponible para poder hacer consultas sobre ella.

Finalmente, una vez creado el disparador, debemos activarlo desde el panel general: